


UV-Net: Learning from Boundary Representations

geometry - the U and V parameter

topology - an adjacency graph

Introduction



sampling points on the edges and faces of solid models

- 솔리드 모델을 표현하기 위한 업계 표준 Boundary representation (B-rep)
- deep neural networks에 적용하기위한 연구에 제한적
- alternate approach
 - point cloud, voxel: fidelity 손실로 고통받고 original B-rep entities로 돌아가는 critical mapping을 잃을 수 있음
 - triangle meshes: non-trivial하고 high quality일 때 쉽게 실패할 수 있음

Related Work

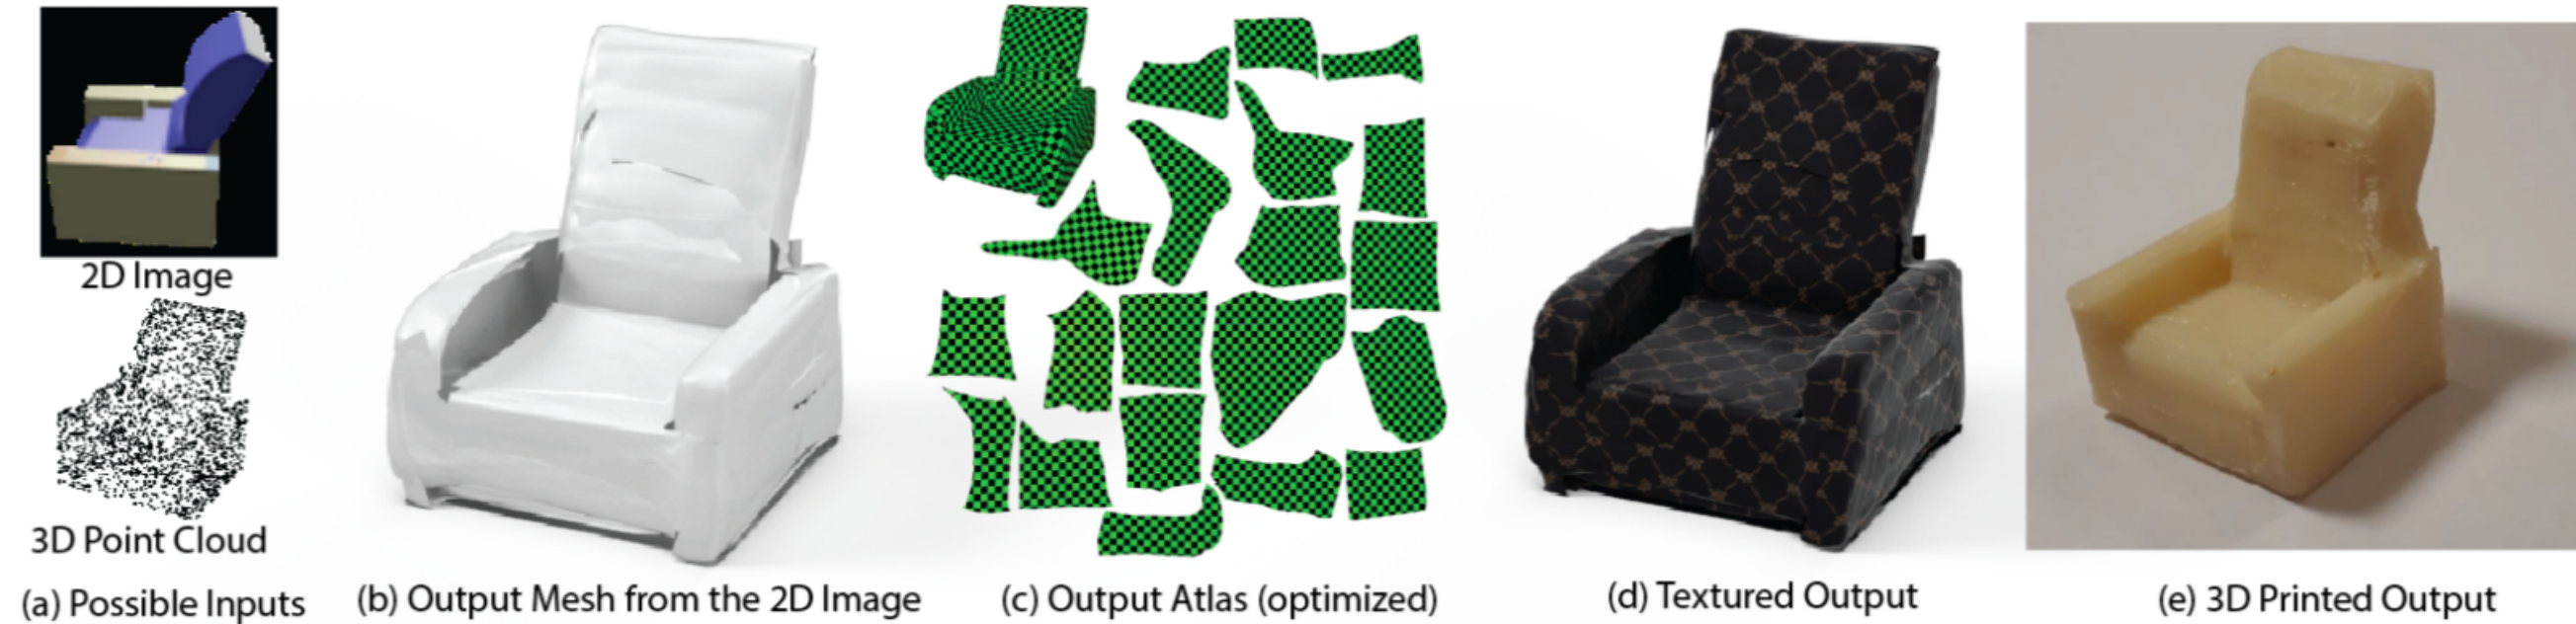
Common geometric representations

- 3D representations: point cloud, voxel, mesh, multi-view image
- 3D CNN: a cubic compute and memory cost
- O-CNN: 일반적인 B-rep data에서 얇은 face에 대해서 아주 deep한 octree가 필요할 수 있음
- signed distance(e.g. DeepSDF), occupancy function: downstream applications을 지원하기 위해 positional encoding과 함께 B-rep face와 edge에 대한 mapping을 학습해야함
- Triangle meshes: B-rep⁰ manifold meshes(watertight)로 변환되어야하며 실패하기 쉬운 어려운 task
- multi-view images: 표현력이 부족
- generation of parametric geometry(Bézier curves, splines, Coons patches, binary space partitioning planes): feature extraction를 다루지 않음

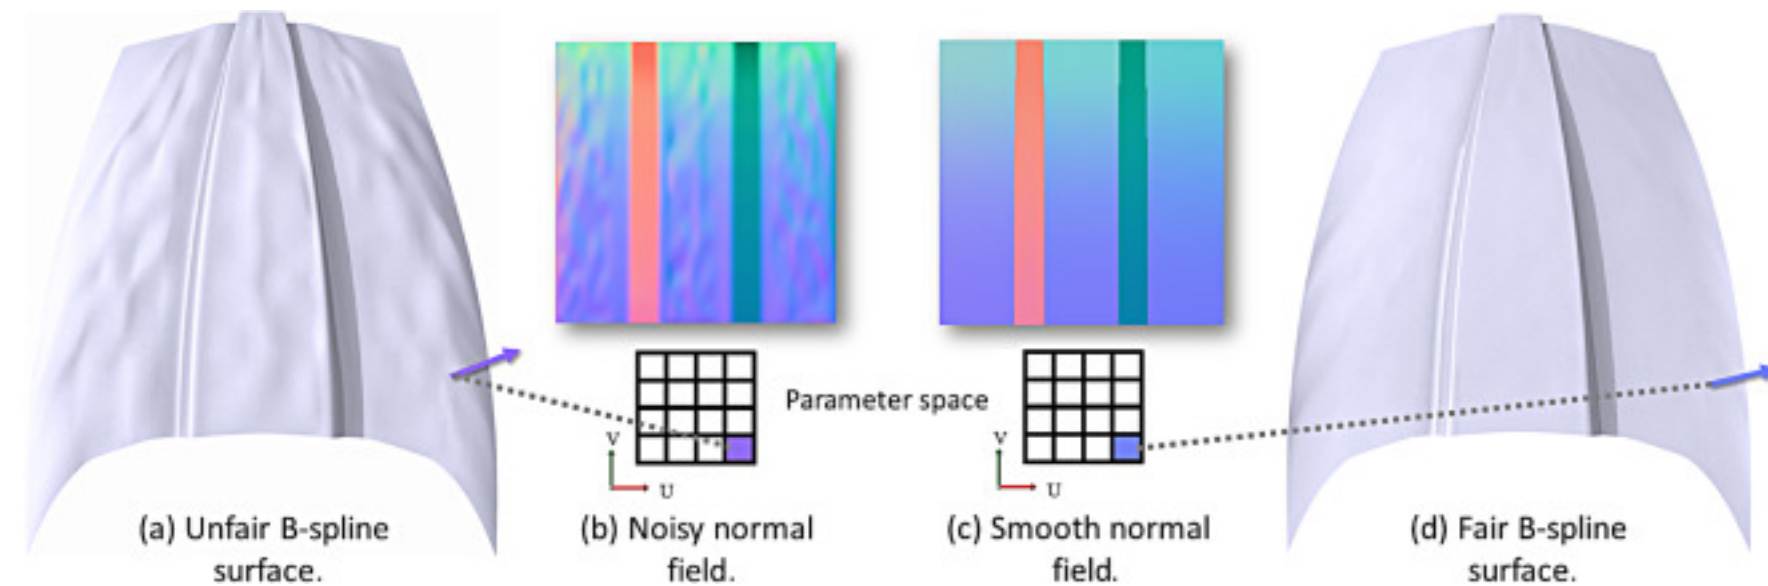
Related Work

3D geometry as images

- CNN을 적용하기 위해 global하게 mesh를 이미지로 parameterize
- point grid를 변형하여 point cloud를 parametrization




- fairing을 위한 B-spline surface의 normal map



Related Work

Boundary representations


- convert the B-rep into a face-adjacency graph (surface type, edge convexity)
 - 다른 task에서 잘 generalize되기 어려움



- B-rep의 면을 face-adjacency graph로 변환하여 분할
 - planar faces를 가진 B-rep에서만 동작

Method

Input representation




(a) Boundary representation

- The B-rep data structure는 여러 topological entities로 구성 – **faces, edges, halfedges, and vertices**, 개체들 사이의 연결 관계를 포함
- 각 face는 하나 이상의 halfedges loop에 의해 구분
- Anti-clockwise loops 는 outer boundaries를 정의하는 반면, clockwise loops는 internal holes을 정의
- Solid model: 모든 edge가 인접 faces에서 two halfedges를 포함
- 모든 인접 entities가 효율적으로 탐색 가능

Method

Input representation - Topology



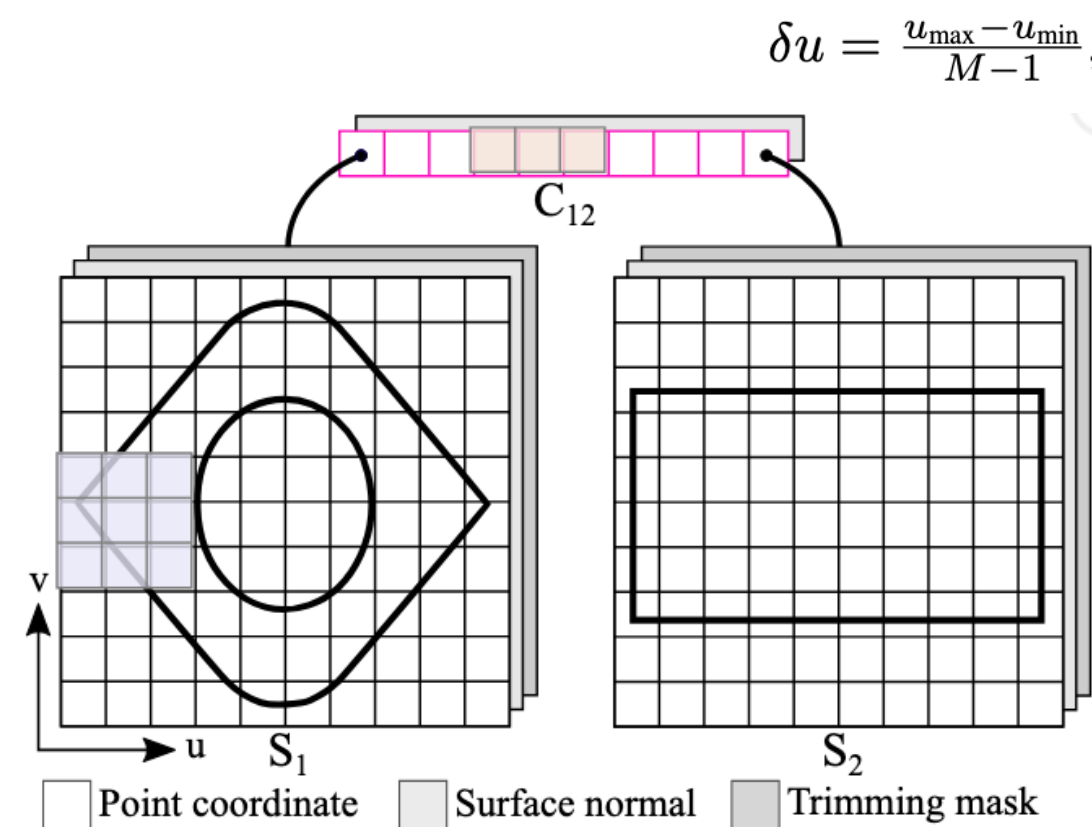
(b) Face-adjacency graph

- vertices V 로 faces를 나타냄
- edges E 는 face 간의 연결성을 인코딩
- halfedges를 통해 인접 face를 찾는데 일정한 time complexity를 가짐
 - current face \rightarrow halfedges \rightarrow twin-halfedges \rightarrow neighboring faces

- face adjacency는 faces, edges를 capture하고 local, global info를 충분히 capture

Method

Input representation - Curve geometry




(c) UV-grids for curves and surfaces

- parametric $C(u)$ 는 $[u_{\min}, u_{\max}]$ 구간을 가지며, 3차원 좌표로 변환
- curve는 line, circular arc, B-spline이 될 수 있음
- 1D grid에 uniform step size만큼 이산화되어 표현
- optional하게 접선 벡터를 추가로 concat하여 붙일 수 있음
 - 접선 벡터는 국소적인 방향성 및 부드러움(곡률 변화) 등의 기하학적 특성을 표현

Method

Input representation - Surface geometry



(c) UV-grids for curves and surfaces

$$\delta u = \frac{u_{\max} - u_{\min}}{M-1}, \text{ and } \delta v = \frac{v_{\max} - v_{\min}}{N-1}$$

- face는 plane, sphere, cylinder, cone, NURBS가 될 수 있음
 - surface는 halfedge loop를 따라 trim -> visible region
 - parametric surface $S(u, v)$ 는 $[u_{\min}, u_{\max}] \times [v_{\min}, v_{\max}]$ 2D 구간을 가지며, 3차원 좌표 공간으로 변환
 - curve와 마찬가지로 2D grid에 uniform step size만큼 이산화되어 표현
 - 파라미터는 visible region에 가까운 값이 선택됨
- grid points index: (k, l)
 - surface feature의 각 channel
 - (1) 3D absolute point position $S(u_k, v_l)$ (2 크기의 cube에 normalize되며 원점에 중심 위치)
 - (2) 3D absolute surface normal $\frac{\mathbf{S}_u(u_k, v_l) \times \mathbf{S}_v(u_k, v_l)}{\|\mathbf{S}_u(u_k, v_l) \times \mathbf{S}_v(u_k, v_l)\|}$ (surface의 특성; 모델이 이동해도 변화 x)
 - (3) Trimming mask (1: visible region, 0: trimmed region)또 다른 채널을 추가 가능

Method

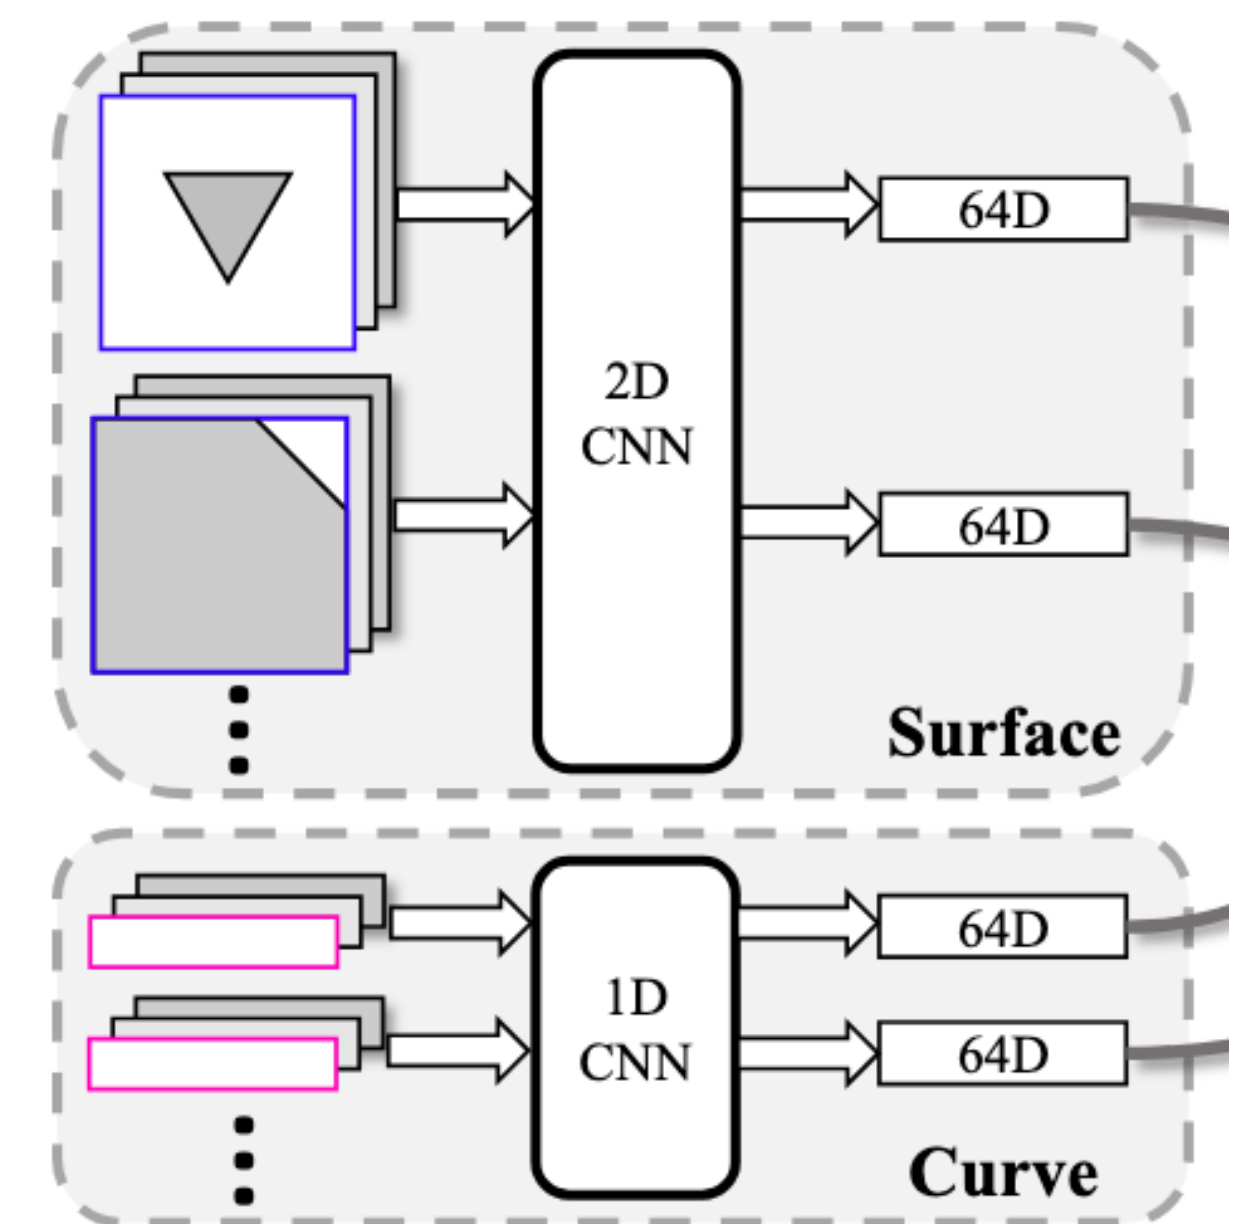
Input representation - Advantages

- (1) Primitive와 Spline surface 모두에서 set of parameter로 빠르게 특징을 계산/추출할 수 있음
- (2) sparse하며 곡선/곡면의 수에 비례하여 확장 가능
- (3) grid는 매개변수화에 불변
 - NURBS 패치로 변환되거나 degree elevation/knot insertion이 수행되어도 기하학적, 매개변수 자체가 동일하게 유지
- (4) UV-grid에서의 local neighborhood가 curve/surface geometry의 local neighborhood에 대응
 - manifold 상에서 hierachical feature extraction이 가능해짐
 - 3D 표면(manifold)을 2D grid에 표현하고, CNN을 사용하여 계층적인 feature를 추출하는 것을 의미

Network architecture

Curve & surface convolution

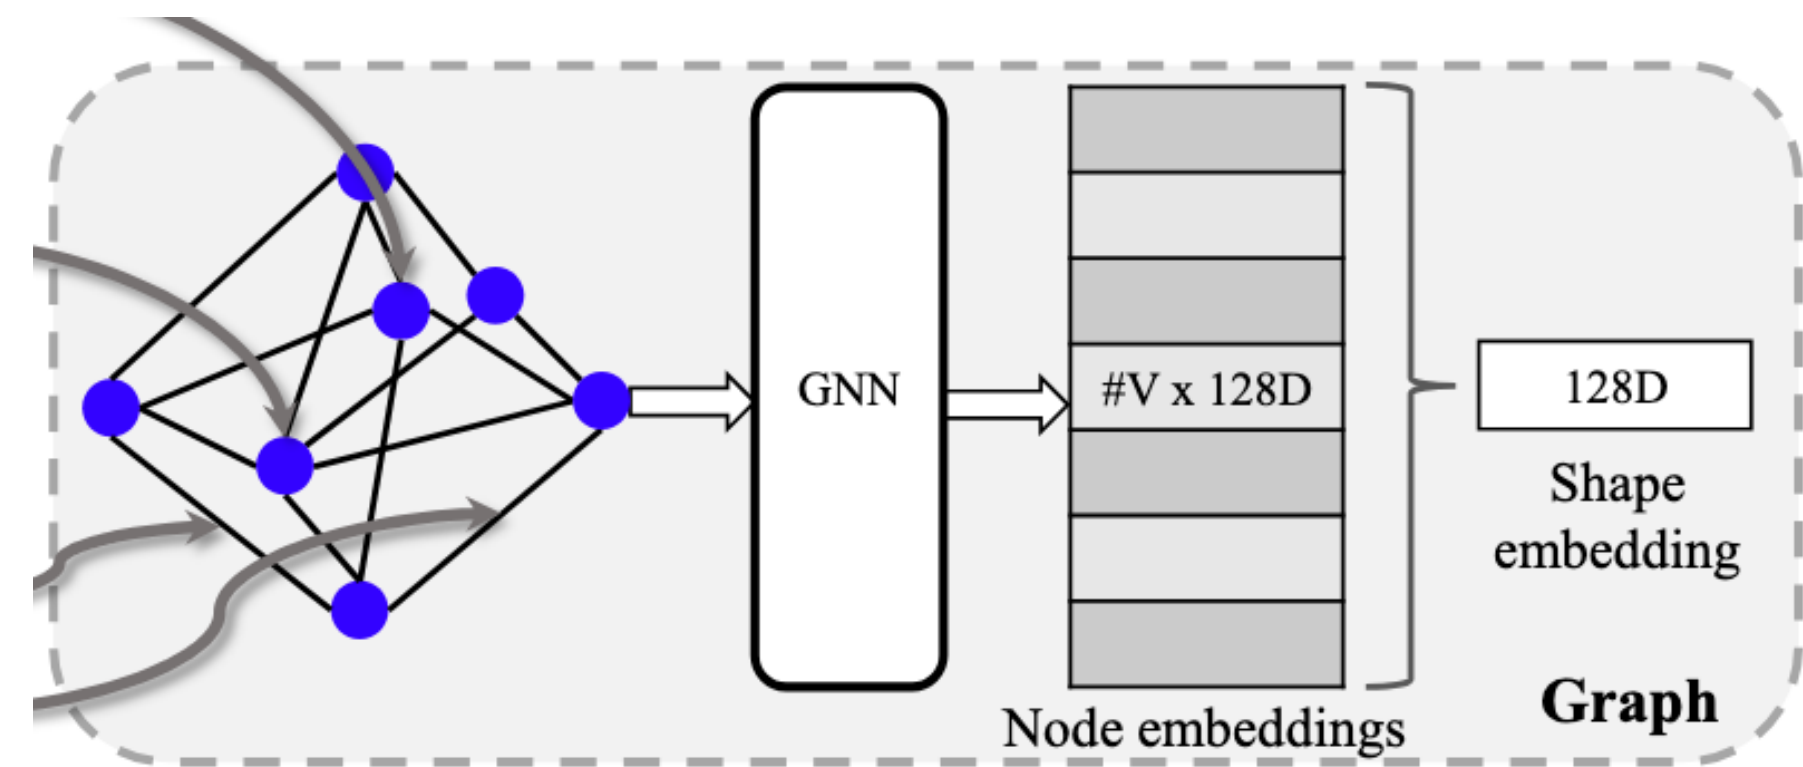
- CNN은 일반적으로 4/7 채널을 가진 UV-grid (3 xyz, 3 normals, 1 trimming mask)를 사용
- Conv(4/7, 64, 3) → Conv(64, 128, 3) → Conv(128, 256, 3) → Pool(1, 1) → FC(256, 64)
- Conv(i, o, k) → i: input channels, o: output channels, k: kernel size
- Pool(n, n) (adaptive average pooling) → output a nxn feature map
- FC(i, o) (fully connected layer) → i: input in i-D vector, o: map to o-D vector
- curve도 유사하게 1D UV-grid와 1D CNN/Pool 을 사용하여 유사하게 정의됨
- 모든 surface와 curve CNN은 weight를 공유하며 permutation invariant
 - permutation invariant: 최종 출력이 순서 변경에 영향을 받지 않아야하는 성질
 - surface F1, F2, F3 순서든 F3, F1, F2 순서든 3D 형상 자체는 불변
- spatial dimension을 입력과 동일하게 유지하기위해 feature는 k/2 크기의 패딩 적용



(c) Image convolutions for curve and surface features

Network architecture

Message passing



- curve와 surface CNN의 output은 GNN의 input edge와 node feature로 다루어짐
- 노드 v 는 1-hop neighborhood에 있는 모든 노드 u 로부터 정보를 수집 (이때 노드 u 와 노드 v 를 연결하는 edge feature에 의해 conditioning)
 - conditioning: edge의 특성에 따라 neighborhood로부터의 정보가 다르게 반영


$$h_v^{(k)} = \phi^{(k)} \left((1 + \epsilon^{(k)}) h_v^{(k-1)} + \sum_{u \in N(v)} f_{\Theta}(h_{uv}^{(k-1)}) \odot h_u^{(k-1)} \right)$$

- $\phi(k)$: MLP(with 2 FC(64, 64) layers)
- $\epsilon^{(k)}$: center와 neighbor 노드를 구별하기위한 learnable parameter (center node의 중요도 조절)
- f_{Θ} : edge를 node feature 공간으로 변환하는 linear projection

Network architecture

Message passing

- hidden edge feature는 endpoint node feature를 고려하며 update



$$h_{uv}^{(k)} = \psi^{(k)} \left((1 + \gamma^{(k)}) h_{uv}^{(k-1)} + f_{\Xi} (h_u^{(k-1)} + h_v^{(k-1)}) \right),$$

- $\psi^{(k)}$: 2-layer MLP(with 2 FC(64, 64) layers)
- $\gamma^{(k)}$: edge와 neighbor 간의 구별을 위한 learnable parameter
- f_{Ξ} : node를 edge feature 공간으로 변환하기위한 linear projection
- hidden node feature에 element-wise max-pooling 적용 $h^{(k)} = \text{maxpool}_{v \in V} (h_v^{(k)})$
- 마지막으로 128D vector로 linearly projection을 하고 summation하여 최종 embedding 획득

$$h_G = \sum_{k=1}^K w^{(k)} \cdot h^{(k)} + b^{(k)}.$$

Experiments

Datasets

Dataset	Type	Features and Uses
SolidLetters	합성, 레이블 O	96k개 모델, 기하학적 및 위상적 변화가 모두 포함되어 균형 잡혀 있음. 분류, 자가 지도 학습에 사용
Machining Feature	합성, 레이블 O	24개 클래스, 기계 가공 특징(예: 챔퍼) 분류에 사용.
MFCAD	합성, 레이블 O	16개 세그멘테이션 레이블, 다중 기계 가공 특징 면 세그멘테이션에 사용.
FabWave	실제(기계 부품), 레이블 O	52개 클래스, 불균형 데이터셋, 분류에 사용.
ABC	실제, 레이블 X (대규모)	46k개 모델 서브셋, 레이블이 없어 자가 지도 학습 및 세그멘테이션 테스트에 사용 (규칙 기반으로 레이블 생성).

Experiments

3D Shape Classification

- 모든 데이터셋(Machining Feature, FabWave, SolidLetters)에서 가장 높은 분류 정확도

Dataset	Model	Accuracy (%)	#Param.
Machining Feature	UV-Net	99.94 ± 0.00	1.34M
	PointNet (2048)	87.13 ± 0.15	0.81M
	DGCNN (2048)	92.81 ± 0.69	1.81M
	FeatureNet (64 ³)	98.85 ± 0.48	33.94M
	MeshCNN (2000)	98.90 ± 0.70	0.67M
FabWave	UV-Net	94.51 ± 0.10	1.35M
	PointNet (2048)	80.08 ± 3.61	0.82M
	DGCNN (2048)	69.95 ± 2.37	1.81M
SolidLetters	UV-Net	97.24 ± 0.10	1.34M
	PointNet (2048)	94.72 ± 0.17	0.81M
	DGCNN (2048)	96.62 ± 0.13	1.81M

Experiments

Segmentation

- MFCAD 데이터셋에서 매우 높은 성능을 달성
- UV-Net은 B-rep 엔티티를 직접 처리함으로써, 메시(Mesh) 기반 방법론에서 요구되는 일관되고 틈이 없는 (watertight, manifold) 메시를 생성해야 하는 어려운 문제를 회피함

Dataset	Model	Accuracy		Per-class accuracy		Intersection-over-Union		#Param.
		Per-face	Per-prim.	Per-face	Per-prim.	Per-face	Per-prim.	
MFCAD	UV-Net	99.95 ± 0.02	-	99.93 ± 0.20	-	99.87 ± 0.03	-	1.23M
	UV-Net (xyz)	99.83 ± 0.06	-	99.80 ± 0.00	-	99.63 ± 0.06	-	1.23M
	PointNet	32.13 ± 7.92	59.13 ± 7.54	16.20 ± 8.51	15.78 ± 8.17	7.15 ± 5.22	8.27 ± 4.66	0.87M
	DGCNN	82.50 ± 2.46	91.60 ± 2.18	80.43 ± 4.51	78.80 ± 4.57	67.70 ± 4.73	78.67 ± 6.27	0.98M
	GNN	-	-	-	-	93.60 [6]	-	0.53M
	MeshCNN	99.89 ± 0.01	98.52 ± 0.04	99.84 ± 0.03	98.29 ± 0.09	99.70 ± 0.06	95.93 ± 0.05	2.29M
ABC	UV-Net	88.87 ± 0.70	-	56.81 ± 0.93	-	50.37 ± 1.11	-	1.23M
	UV-Net (xyz)	77.33 ± 0.48	-	47.38 ± 0.54	-	38.99 ± 0.42	-	1.23M
	PointNet	40.77 ± 1.79	61.27 ± 0.55	19.87 ± 0.51	25.53 ± 0.32	11.10 ± 0.70	18.47 ± 0.31	0.87M
	DGCNN	54.18 ± 3.19	67.80 ± 0.59	27.30 ± 1.34	34.93 ± 1.52	18.14 ± 1.97	26.26 ± 1.27	0.98M

Experiments

Self-supervised learning

- B-rep 데이터로 decoder를 설계하는 것은 어려운 문제 (후속 연구 SolidGen, BrepGen)
- label이 없는 데이터로 학습시키기위해 contrastive learning(CLR)을 활용
- 모델에 prior을 주입하기 위해 Connected patch, Drop nodes, Drop edges 등의 transformation 기법을 사용하여 Positive 생성
 - Connected patch: 임의의 node와 $n(1\sim 2)$ -hop neighbor 추출
 - Drop nodes: 연결된 edge와 함께 uniform probability 0.4로 node를 무작위 삭제
 - Drop edges: uniform probability 0.4로 edge를 무작위 삭제
- UV-Net 인코더를 사용하여 128D embedding(positive pair)을 추출하고 3-layer non-linear MLP를 거쳐 64D latent vector(z)로 매핑

- SolidLetters에서 SVM classification 79.4% 달성


Method	Score (%)
Linear SVM	79.40 \pm 0.20
K-means clustering	58.17 \pm 0.25

Experiments

Sensitivity to sampling

- input 데이터의 sampling 해상도가 낮아져도 robust한 성능을 보임


Method	Score (%)
Linear SVM	79.40 \pm 0.20
K-means clustering	58.17 \pm 0.25



Experiments

Feature and architecture ablation

- Full UV-Net (xyz only): normal을 제거하고 xyz 좌표 및 trim mask 사용
- UV-Net (Faces only): surface CNN과 GNN만 사용
- Face features only: GNN 부분을 MLP로 대체하고 edge feature 제거
- Topology only: curve와 surface CNN을 제거하고 edge와 node 속성을 normal distribution에서 sampled noise로 설정하여 topology만 사용



Experiments

Invariance to reparametrization

- U 와 V axis를 따라 surface parametrization을 reverse하는 것은 UV-grid를 해당 axis에 따라 flip하는 것과 같음
- U 와 V axis를 exchange하여 surface parametrization을 transpose하는 것은 UV-grid를 rotate, flip하는 것과 같음
- 이러한 rotate, flip에 대해 Regular Image Convolution은 Invariant하지 않음
- 아래 실험 결과를 통해 reparametrization한 테스트 데이터셋에 대해 성능이 크게 감소한 것을 확인
- 반면 equivariant convolution을 적용했을 때 정확도 유지

Convolution	Reparametrized	Test Accuracy
Regular	No	96.74 \pm 0.06
	Yes	55.98 \pm 2.36
D ₂ equivariant	No	96.58 \pm 0.01
	Yes	96.59 \pm 0.02

Conclusion

Limitations & future work

- curve와 surface에 대해 geometry 특성과 관계없이 sampling step size를 고정하여 사용
- curve, surface type, edge convexity, halfedge ordering 등 B-rep에서 사용할 수 있는 모든 정보를 활용하지 않음
- rotation-invariant 부족 -> 다양한 face, edge의 relative orientation을 인지하는데 영향을 줄 수 있음
- ABC와 같은 large dataset으로 transfer learning을 위해 self-supervised method를 개선할 수 있는 잠재력이 있음
- subdivision surface와 같은 다른 3D 표현 방식에 어떻게 적용할 수 있을지 조사할 가치가 있음